

Documentation Technique de l'Algorithme de Similarité

ChatBot SUP'PTIC

Document de référence pour l'équipe projet
détaillant l'architecture logicielle et le fonctionnement
du moteur de recherche basé sur TF-IDF et Similarité Cosinus

Table des matières

1	Introduction	2
1.1	Objectif du Document	2
1.2	Ce que Vous Allez Apprendre	2
1.3	Public Cible	2
2	L'Algorithme de Similarité : Cur du Système	3
2.1	Vue d'Ensemble	3
2.2	TF-IDF : Donner un Poids aux Mots	3
2.2.1	Qu'est-ce que TF-IDF ?	3
2.2.2	Exemple Concret avec Notre FAQ	3
2.3	Similarité Cosinus : Mesurer la Proximité	5
2.3.1	Le Concept Géométrique	5
2.3.2	Exemple de Calcul Complet	5
2.4	Exemple avec les Programmes Académiques	7
3	Importance Cruciale des Données CSV	8
3.1	Structure Standard des Fichiers CSV	8
3.2	Pourquoi la Qualité des Questions est Critique	8
3.2.1	Rappel du Principe	8
3.2.2	Exemples de Bonnes et Mauvaises Questions	8
3.3	Importance des Variantes de Questions	10
3.4	Cas Réels de Notre Base de Données	10
3.4.1	Exemple 1 : Clubs - Question Bien Formulée	10
3.4.2	Exemple 2 : Programmes - Question Précise	11
3.4.3	Exemple 3 : Clubs - Question à Améliorer	11
3.5	Impact du Vocabulaire Riche	12
3.5.1	Synonymes et Variantes Linguistiques	12
3.5.2	Exemple Réel : Diversité du Vocabulaire	12
3.6	Structure CSV et Catégorisation	12
3.6.1	Importance des Métadonnées	12
3.6.2	Catégories Actuelles	13
3.7	Règles d'Or pour la Qualité des Données	14
3.8	Checklist de Validation d'une Entrée CSV	14

1 Introduction

1.1 Objectif du Document

Ce guide technique a pour objectif de démystifier le fonctionnement du ChatBot SUP'PTIC pour tous les membres de l'équipe, qu'ils soient développeurs, designers, gestionnaires de contenu ou nouveaux arrivants.

Périmètre

Ce document se concentre **uniquement** sur la conception du bot et l'algorithme sous-jacent. Les aspects suivants sont **exclus** :

- La phase de collecte des données (traitée dans un document séparé)
- Le code source détaillé (disponible sur le dépôt GitHub)
- Les maquettes d'interface utilisateur (document architecture séparé)
- Les procédures de déploiement

1.2 Ce que Vous Allez Apprendre

À la fin de ce document, vous serez capable de :

1. **Comprendre l'algorithme** : Saisir comment TF-IDF et la similarité cosinus permettent au chatbot de trouver la bonne réponse
2. **Apprécier l'importance des données CSV** : Comprendre pourquoi la qualité de nos fichiers CSV détermine directement la performance du système
3. **Contribuer efficacement** : Savoir comment améliorer les données pour optimiser les résultats
4. **Naviguer dans l'arborescence** : Connaître l'organisation du code pour savoir où intervenir

1.3 Public Cible

Ce document s'adresse à :

- Les développeurs backend et frontend de l'équipe
- Les gestionnaires de contenu responsables de la FAQ
- Les designers UX/UI qui conçoivent l'interface
- Les nouveaux membres rejoignant le projet
- Tout membre de l'équipe souhaitant comprendre le système

Prérequis

Aucune connaissance préalable en intelligence artificielle n'est requise. Les concepts mathématiques sont expliqués avec des exemples concrets tirés de notre projet.

2 L'Algorithme de Similarité : Cur du Système

2.1 Vue d'Ensemble

Le chatbot SUP'PTIC repose sur un principe simple mais puissant : **transformer les phrases en nombres pour pouvoir les comparer mathématiquement.**

Principe Fondamental

Quand un utilisateur pose une question, le système :

1. Transforme la question en un vecteur de nombres (TF-IDF)
2. Transforme toutes les questions de la FAQ en vecteurs
3. Calcule la distance entre la question utilisateur et chaque question FAQ (similarité cosinus)
4. Retourne la réponse associée à la question FAQ la plus proche

2.2 TF-IDF : Donner un Poids aux Mots

2.2.1 Qu'est-ce que TF-IDF ?

TF-IDF (Term Frequency - Inverse Document Frequency) est une technique statistique qui évalue l'importance d'un mot dans un document par rapport à un corpus de documents.

TF : Fréquence du Terme La fréquence du terme (TF) mesure simplement combien de fois un mot apparaît dans une phrase.

$$TF(mot, phrase) = \frac{\text{nombre d'occurrences du mot dans la phrase}}{\text{nombre total de mots dans la phrase}}$$

IDF : Fréquence Inverse du Document La fréquence inverse du document (IDF) mesure la rareté d'un mot dans l'ensemble du corpus. Un mot rare est plus discriminant qu'un mot courant.

$$IDF(mot) = \log \frac{N}{n_t}$$

où N est le nombre total de documents (questions FAQ) et n_t le nombre de documents contenant le mot.

TF-IDF : La Combinaison Le score TF-IDF final combine les deux mesures :

$$TF-IDF(mot, phrase) = TF(mot, phrase) \times IDF(mot)$$

2.2.2 Exemple Concret avec Notre FAQ

Prenons un exemple tiré de notre base de données réelle sur les clubs et associations :

Calcul TF-IDF - Exemple Réel

Question utilisateur :

"Quels sont les frais d'adhésion au club informatique ?"

Questions FAQ candidates :

1. *"Quels sont les documents nécessaires pour adhérer au club informatique ?"*
2. *"Est-ce que les frais d'adhésion sont remboursables ?"*

Analyse des mots clés :

- Le mot **"frais"** apparaît dans la question utilisateur et dans la FAQ 2, mais **pas** dans la FAQ 1
- Le mot **"adhésion"** apparaît dans les trois phrases
- Le mot **"club"** apparaît dans la question utilisateur et la FAQ 1
- Le mot **"informatique"** apparaît dans la question utilisateur et la FAQ 1

Calcul simplifié (supposons 100 questions dans notre base) :

Pour la question utilisateur "Quels sont les frais d'adhésion au club informatique ?" (8 mots) :

- Si "frais" apparaît dans 12 questions : $IDF(\text{frais}) = \log(100/12) \approx 2.12$
- $TF(\text{frais}) = 1/8 = 0.125$
- $TF-IDF(\text{frais}) = 0.125 \times 2.12 = 0.27$
- Si "adhésion" apparaît dans 25 questions : $IDF(\text{adhésion}) = \log(100/25) \approx 1.39$
- $TF(\text{adhésion}) = 1/8 = 0.125$
- $TF-IDF(\text{adhésion}) = 0.125 \times 1.39 = 0.17$
- Si "club" apparaît dans 40 questions : $IDF(\text{club}) = \log(100/40) \approx 0.92$
- $TF(\text{club}) = 1/8 = 0.125$
- $TF-IDF(\text{club}) = 0.125 \times 0.92 = 0.12$

Observation : Le mot "frais" a le score TF-IDF le plus élevé car il est plus discriminant.

2.3 Similarité Cosinus : Mesurer la Proximité

2.3.1 Le Concept Géométrique

Une fois que nous avons transformé les phrases en vecteurs de nombres, nous devons mesurer leur similarité. La similarité cosinus calcule l'angle entre deux vecteurs dans un espace multidimensionnel.

$$\text{similarité}(\vec{A}, \vec{B}) = \frac{\vec{A} \cdot \vec{B}}{\|\vec{A}\| \times \|\vec{B}\|}$$

où :

- $\vec{A} \cdot \vec{B}$ est le produit scalaire (somme des produits des composantes)
- $\|\vec{A}\|$ est la norme du vecteur $\vec{A}$ (racine carrée de la somme des carrés)
- $\|\vec{B}\|$ est la norme du vecteur $\vec{B}$

Le résultat varie entre 0 (totalement différent) et 1 (identique).

2.3.2 Exemple de Calcul Complet

Reprenons notre exemple précédent avec un calcul complet (simplifié à 3 dimensions pour la clarté).

Calcul de Similarité - Pas à Pas

Supposons que nous ne considérons que 3 mots : [frais, adhésion, club]

Question utilisateur :

"Quels sont les frais d'adhésion au club informatique ?"

Vecteur : $\vec{A} = [0.27, 0.17, 0.12]$ (scores TF-IDF calculés précédemment)

FAQ 1 :

"Quels sont les documents nécessaires pour adhérer au club informatique ?"

Vecteur : $\vec{B}_1 = [0.00, 0.18, 0.13]$ (pas de "frais", mais "adhésion" et "club")

FAQ 2 :

"Est-ce que les frais d'adhésion sont remboursables ?"

Vecteur : $\vec{B}_2 = [0.28, 0.19, 0.00]$ ("frais" et "adhésion", mais pas "club")

Calcul de similarité($\vec{A}, \vec{B}_1$) :

1. Produit scalaire :

$$\begin{aligned}\vec{A} \cdot \vec{B}_1 &= (0.27 \times 0.00) + (0.17 \times 0.18) + (0.12 \times 0.13) \\ &= 0 + 0.0306 + 0.0156 \\ &= 0.0462\end{aligned}$$

2. Norme de $\vec{A}$:

$$\begin{aligned}\|\vec{A}\| &= \sqrt{0.27^2 + 0.17^2 + 0.12^2} \\ &= \sqrt{0.0729 + 0.0289 + 0.0144} \\ &= \sqrt{0.1162} \approx 0.341\end{aligned}$$

3. Norme de $\vec{B}_1$:

$$\begin{aligned}\|\vec{B}_1\| &= \sqrt{0.00^2 + 0.18^2 + 0.13^2} \\ &= \sqrt{0 + 0.0324 + 0.0169} \\ &= \sqrt{0.0493} \approx 0.222\end{aligned}$$

4. Similarité :

$$\begin{aligned}\text{similarité}(\vec{A}, \vec{B}_1) &= \frac{0.0462}{0.341 \times 0.222} \\ &= \frac{0.0462}{0.0757} \\ &\approx 0.61 \text{ soit } \mathbf{61\%}\end{aligned}$$

Calcul de similarité($\vec{A}, \vec{B}_2$) :

1. Produit scalaire :

$$\begin{aligned}\vec{A} \cdot \vec{B}_2 &= (0.27 \times 0.28) + (0.17 \times 0.19) + (0.12 \times 0.00) \\ &= 0.0756 + 0.0323 + 0 \\ &= 0.1079\end{aligned}$$

2. Norme de $\vec{B}_2$:

$$\begin{aligned}\|\vec{B}_2\| &= \sqrt{0.28^2 + 0.19^2 + 0.00^2} \\ &= \sqrt{0.0784 + 0.0361 + 0} \\ &= \sqrt{0.1145} \approx 0.338\end{aligned}$$

2.4 Exemple avec les Programmes Académiques

Prenons maintenant un exemple tiré de notre FAQ sur les programmes académiques :

Application aux Programmes

Question utilisateur :

"Combien de temps dure la formation d'ingénieur des télécommunications ?"

Questions FAQ candidates :

1. *"Quelle est la durée de formation pour devenir Ingénieur des Télécommunications ?"*
2. *"Quelle est la durée de formation pour devenir Technicien des Télécommunications ?"*
3. *"Quel diplôme obtient-on après le second cycle d'ingénierie ?"*

Analyse :

Mots clés communs :

- **"durée"** et **"formation"** : présents dans la question utilisateur, FAQ 1 et FAQ 2
- **"Ingénieur"** : présent dans la question utilisateur, FAQ 1 et FAQ 3
- **"Télécommunications"** : présent dans toutes les questions
- **"Technicien"** : uniquement dans FAQ 2 (différent de "Ingénieur")

Pourquoi FAQ 1 aura le meilleur score :

1. Elle contient **tous** les mots clés de la question utilisateur
2. La structure de la phrase est très similaire
3. Le mot "durée" est un terme discriminant qui apparaît explicitement
4. Même si FAQ 3 contient "Ingénieur", elle ne mentionne pas "durée" ou "formation"

Scores estimés (simplifié) :

- FAQ 1 : $\approx 95\%$ (quasi-identique)
- FAQ 2 : $\approx 70\%$ (similaire mais "Technicien" $\neq$ "Ingénieur")
- FAQ 3 : $\approx 45\%$ (manque les mots clés "durée" et "formation")

Leçon Importante

Plus la question dans notre CSV est formulée de manière proche de ce qu'un utilisateur réel demanderait, meilleur sera le score de similarité. C'est pourquoi nous devons :

- Utiliser un vocabulaire naturel et varié
- Inclure plusieurs variantes de la même question
- Penser comme un étudiant qui pose une question

3 Importance Cruciale des Données CSV

3.1 Structure Standard des Fichiers CSV

Nos fichiers CSV respectent rigoureusement la structure suivante :

Listing 1 – Format CSV Standard

Question , Reponse , Categorie , SousTheme , Source

Colonnes du CSV

Question : La question telle qu'un utilisateur pourrait la poser naturellement
Reponse : La réponse complète, précise et vérifiée
Categorie : Catégorie thématique principale (ex : "Vie Étudiante", "Programmes académiques")
SousTheme : Sous-thème plus précis (ex : "Clubs et associations", "Présentation des filières")
Source : Référence ou contributeur de l'information

3.2 Pourquoi la Qualité des Questions est Critique

3.2.1 Rappel du Principe

L'algorithme TF-IDF calcule la similarité entre :

- La question posée par l'utilisateur
- Les questions stockées dans notre fichier CSV

Conséquence Directe

Si nos questions CSV sont mal formulées, l'algorithme ne trouvera **jamais** la bonne réponse, même si nous l'avons dans notre base de données !

3.2.2 Exemples de Bonnes et Mauvaises Questions

Mauvaise Formulation

Question CSV mal formulée :

Question: FAQ_CLUB_001 Reponse: Pour s'inscrire à un club cette année, il faut... Categorie: Vie Étudiante
--

Problème :

- "FAQ_CLUB_001" ne contient aucun mot clé significatif
- Si un utilisateur demande "Comment s'inscrire à un club?", le score TF-IDF sera proche de zéro
- Aucune correspondance possible avec une vraie question

Bonne Formulation - Exemple Réel

Question CSV bien formulée (extrait de notre base réelle) :

Question: Comment s'inscrire à un club cette année ?

Reponse: Pour s'inscrire à un club cette année, il faut se rapprocher du président du club pour se renseigner sur la procédure d'intégration du club.

Categorie: Vie Étudiante

SousTheme: Clubs et associations

Source: Contributeur

Avantages :

- Mots clés pertinents : "inscrire", "club", "année"
- Formulation naturelle comme un étudiant poserait la question
- Si un utilisateur demande "inscription club" ou "comment rejoindre un club", le score sera élevé

3.3 Importance des Variantes de Questions

Pour maximiser la couverture et la précision, nous devons inclure plusieurs variantes pour chaque réponse.

Variantes - Clubs et Associations

Pour la même réponse sur l'inscription aux clubs, nous pourrions avoir :

Variante 1 (actuelle dans notre base) :

Comment s'inscrire à un club cette année ?

Variante 2 (à ajouter) :

Quelle est la procédure pour rejoindre un club ?

Variante 3 (à ajouter) :

Comment faire pour devenir membre d'une association ?

Variante 4 (à ajouter) :

Inscription club étudiant procédure

Avantages :

- Variante 1 : Couvre "inscrire", "club", "année"
- Variante 2 : Couvre "procédure", "rejoindre"
- Variante 3 : Couvre "devenir", "membre", "association"
- Variante 4 : Couvre les recherches avec mots-clés uniquement

Chaque variante augmente les chances qu'un utilisateur trouve la bonne réponse!

3.4 Cas Réels de Notre Base de Données

Analysons quelques exemples tirés de nos fichiers CSV existants :

3.4.1 Exemple 1 : Clubs - Question Bien Formulée

Listing 2 – Extrait réel - Vie Étudiante

Question: Est-ce que je peux m'inscrire à plusieurs clubs en même temps ?

Reponse: Oui tu peux t'inscrire à plusieurs clubs au même moment.

Categorie: Vie Étudiante

SousTheme: Clubs et associations

Source: Contributeur

Pourquoi c'est bien

- Question complète et naturelle
- Mots clés : "inscrire", "plusieurs", "clubs", "même temps"
- Un utilisateur qui demande "peut-on adhérer à 2 clubs" obtiendra un bon score
- Réponse courte et directe

3.4.2 Exemple 2 : Programmes - Question Précise

Listing 3 – Extrait réel - Programmes académiques

Question: Quelle est la durée de formation pour devenir Ingénieur des Télécommunications ?
Reponse: La formation dure 2 ans.
Categorie: Programmes académiques
SousTheme: Présentation des filières
Source: À vérifier auprès de SUP'PTIC - <https://e-supptic.cm/>

Pourquoi c'est bien

- Question très spécifique avec tous les mots clés nécessaires
- "durée", "formation", "Ingénieur", "Télécommunications"
- Correspond exactement à ce qu'un candidat demanderait
- Réponse concise et factuelle

3.4.3 Exemple 3 : Clubs - Question à Améliorer

Listing 4 – Question qui pourrait être enrichie

Question: Quel club choisir si je suis passionné de jeux vidéo ?
Reponse: Le club jeu et loisirs.
Categorie: Vie Étudiante
SousTheme: Clubs et associations
Source: Contributeur

Suggestions d'Amélioration

Cette question est bonne, mais nous pourrions ajouter des variantes :

- "Y a-t-il un club pour les amateurs de jeux vidéo ?"
- "Club gaming SUP'PTIC existe ?"
- "Quel club pour les gamers à l'école ?"

Cela augmenterait la couverture pour différentes formulations.

3.5 Impact du Vocabulaire Riche

3.5.1 Synonymes et Variantes Linguistiques

Les utilisateurs utilisent des mots différents pour exprimer la même idée. Notre CSV doit refléter cette diversité.

Richesse du Vocabulaire

Pour poser une question sur les frais, un utilisateur peut dire :

- "Quels sont les **frais** d'inscription ?"
- "Combien **coûte** l'inscription ?"
- "Quel est le **montant** à payer ?"
- "Quel est le **prix** de l'inscription ?"
- "Quel est le **tarif** pour s'inscrire ?"

Mots clés à couvrir : frais, coûte, coût, montant, prix, tarif, payer, paiement

Solution : Créer plusieurs variantes dans notre CSV utilisant ces différents termes.

3.5.2 Exemple Réel : Diversité du Vocabulaire

Voici comment notre base actuelle gère différentes formulations :

Listing 5 – Variantes dans notre base

```
# Variante 1
Question: Comment créer un nouveau club à SUP'PTIC ?
Reponse: Pour créer un nouveau club à SUP'PTIC, il faut écrire une
demande...

# Variante 2 (à ajouter)
Question: Quelle est la procédure pour lancer une nouvelle association ?
Reponse: [même réponse]

# Variante 3 (à ajouter)
Question: Comment faire pour fonder un club étudiant ?
Reponse: [même réponse]
```

Vocabulaire couvert :

- Variante 1 : "créer", "nouveau", "club"
- Variante 2 : "procédure", "lancer", "association"
- Variante 3 : "faire", "fonder", "étudiant"

3.6 Structure CSV et Catégorisation

3.6.1 Importance des Métadonnées

Les colonnes *Categorie*, *SousTheme* et *Source* ne sont pas utilisées directement par l'algorithme de similarité, mais elles sont cruciales pour :

1. **Organisation** : Faciliter la gestion et la maintenance des données
2. **Filtrage** : Permettre des recherches par catégorie si nécessaire
3. **Validation** : Tracer la source de l'information pour vérification
4. **Évolution** : Identifier les zones à enrichir

3.6.2 Catégories Actuelles

D'après nos données existantes, nous avons identifié ces catégories principales :

- **Vie Étudiante** (Clubs et associations)
- **Programmes académiques** (Présentation des filières)
- **Inscriptions & Admissions**
- **Examens & Évaluations**
- **Services administratifs**
- **Infrastructures & Ressources**
- **Carrières & Insertion**
- **Communication & Vie institutionnelle**
- **Vie pratique**

3.7 Règles d'Or pour la Qualité des Données

10 Règles d'Or

1. **Formulez comme un utilisateur réel** : Écrivez les questions comme un étudiant les poserait naturellement
2. **Soyez spécifique** : "Quels sont les frais d'inscription en L1 ?" plutôt que "Frais L1"
3. **Incluez des variantes** : Minimum 2-3 formulations différentes par réponse
4. **Utilisez un vocabulaire riche** : Synonymes, expressions courantes, jargon étudiant
5. **Respectez la structure CSV** : Ne jamais omettre une colonne, même si "À compléter"
6. **Vérifiez la source** : Toujours indiquer l'origine de l'information
7. **Réponses concises mais complètes** : Direct et informatif, sans superflu
8. **Testez vos questions** : Posez-vous "comment un étudiant demanderait-il cela ?"
9. **Évitez les codes** : "Comment s'inscrire au club ?" plutôt que "FAQ_CLUB_001"
10. **Mettez à jour régulièrement** : Les informations évoluent (présidents de clubs, dates, etc.)

3.8 Checklist de Validation d'une Entrée CSV

Avant d'ajouter une nouvelle ligne à votre fichier CSV, vérifiez :

1. La question est-elle formulée en langage naturel ?
2. Contient-elle au moins 5 mots significatifs ?
3. Ai-je créé 2-3 variantes de cette question ?
4. La réponse est-elle précise et vérifiée ?
5. La catégorie et le sous-thème sont-ils corrects ?
6. La source est-elle indiquée ?
7. Aucune colonne n'est vide (sauf si "À compléter")
8. Le format CSV est-il respecté (virgules, guillemets si nécessaire)
9. Ai-je relu pour détecter les fautes d'orthographe ?
10. Un utilisateur réel poserait-il la question ainsi ?